



Procesamiento de Imágenes Biomédicas 16.16

---

## **Detección de Melanomas a partir de Técnicas de Procesamiento de Imágenes y Machine Learning**

---

Grupo 2:

Barzi, Milagros	61138
Insussarry Perkins, Catalina	61087
Stirparo, Ludmila	60055
Zoani, Bárbara	61088

## Índice

<b>Introducción</b>	<b>2</b>
Métodos actuales de clasificación	2
<b>Base de datos</b>	<b>3</b>
<b>Procesamiento de imágenes</b>	<b>3</b>
Segmentación	4
Extracción de características	5
Asimetría	5
Irregularidad de los bordes y Desviación del Círculo	5
Bordes internos	7
Cantidad de colores	7
Azul blanquecino	7
Intensidad capa azul	8
Métricas de texturas	8
Energía	8
Entropía	9
Correlación	9
Machine Learning	9
Métricas de evaluación	10
<b>Resultados</b>	<b>10</b>
Interfaz	10
<b>Conclusión</b>	<b>11</b>
<b>Bibliografía</b>	<b>12</b>
<b>Anexo</b>	<b>13</b>
<b>Tabla 1: Rangos utilizados para determinar la cantidad de colores</b>	<b>13</b>
<b>Tabla 2: Rangos utilizados para determinar la presencia de azul blanquecino</b>	<b>13</b>

## **Introducción**

El melanoma es un tipo de cáncer de piel que se origina por el crecimiento descontrolado de los melanocitos, es decir, las células pigmentarias de la piel. Generalmente, se desarrollan en zonas adyacentes a lunares o sobre ellos, o crecen aleatoriamente en la piel y poseen características físicas que permiten su identificación. Sin embargo, es un tipo de cáncer agresivo, que crece con rapidez y genera metástasis en otros órganos a una velocidad que dificulta su tratamiento, causando el 75% de las muertes por cánceres de piel.

La detección temprana del melanoma es fundamental para el tratamiento y la recuperación del paciente: aumenta la tasa de supervivencia hasta un 95%. Es por este motivo que es imprescindible contar con herramientas que permitan detectar y clasificar melanomas de manera sencilla y eficaz.

## **Métodos actuales de clasificación**

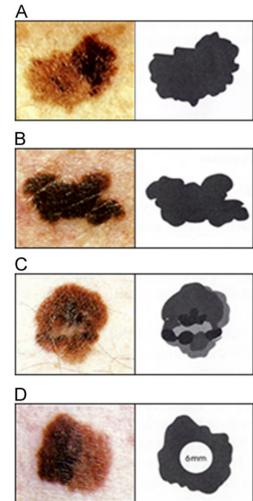
La metodología utilizada actualmente para la detección de cáncer de piel consiste en un examen de *screening* que lo lleva a cabo un dermatólogo. Los dermatólogos utilizan distintas técnicas para evaluar las características de las lesiones cutáneas, siendo el más utilizado el Método de ABCD, entre otros. Estos métodos permiten analizar las lesiones de una persona en busca de determinar si alguna de éstas requiere de un análisis más profundo, y al ser sencillos permiten que puedan ser utilizadas por profesionales inexpertos.

Estos criterios se usan para decidir si la lesión se trata de una sospechosa o no sospechosa. Seguido de esto, se realiza una biopsia de los lunares para confirmar el diagnóstico presuntivo y definir la patología de la lesión.

La regla ABCD consiste en el estudio de la morfología del posible melanoma e implica el análisis de los siguientes factores:

1. Asimetría: existe un eje que divide al lunar en dos mitades distintas entre sí.
2. Borde: los bordes son irregulares e indefinidos.
3. Color: el color no es uniforme.
4. Diámetro: mayor a 6mm.

En caso de verificar alguno de los criterios, que se observan en la figura 1, es altamente probable que se trate de un melanoma.



El desarrollo de un software que detecte automáticamente el riesgo de una lesión en la piel a partir de los resultados histopatológicos sería de mucha utilidad ya que reduciría significativamente el tiempo de análisis de los médicos. Demás está decir que no se busca reemplazar la necesidad de realizar una biopsia para confirmar el diagnóstico de la lesión, sino el proceso evaluativo y visual de los médicos.

Considerando esta información, el presente trabajo consiste en el procesamiento de las imágenes y el posterior desarrollo de un algoritmo de *machine learning* que detecte melanomas, clasificando lesiones en benignas o malignas según ciertas características visuales como la asimetría, la circularidad, la irregularidad de los bordes, bordes internos, la cantidad de colores, algunas métricas de textura y la presencia de azul blanquecino. Es importante extraer dichos parámetros numéricamente para lograr correlacionar los distintos valores con la probabilidad de que sea benigno o maligno.

Entonces, el método propuesto consta de tres etapas: la segmentación de la lesión, la extracción de características y la clasificación del lunar mediante un modelo de *Machine Learning*.

## **Base de datos**

Las imágenes utilizadas corresponden a la base de datos de International Skin Imaging Collaboration (ISIC), que contiene más de 10.000 imágenes dermatoscopias etiquetadas según su diagnóstico

histopatológico. Cabe destacar que se trata de la colección de imágenes dermatoscopias de lesiones cutáneas más grande disponible públicamente. Todas las imágenes se encuentran en formato JPG.

Se eligió trabajar con un número reducido de imágenes extraídas de esta base de datos para poder verificar el correcto funcionamiento de los algoritmos visualmente. Además, se tuvieron en consideración las limitaciones propias de la RAM de Google Colab a la hora de cargar imágenes.

Las 175 imágenes fueron seleccionadas manualmente y de manera aleatoria de la base de datos. Únicamente se revisó que no estuviera incluidas aquellas que presentaran algunas de las siguientes características:

- Imágenes que contienen pelos gruesos: los algoritmos utilizados para eliminar el vello deterioran mucho la imagen.
- Imágenes que predomina la luz azul en el fondo: causan que el algoritmo de detección de velo azul blanquecino presente errores.
- Presencia de artefactos no asociados a la lesión: artefactos como marcadores de otros colores o errores en la forma de adquisición, no tratándose de imágenes dermatoscopias.
- Imágenes con bordes negros: Esto se debe a que estas imágenes dificultan el proceso de segmentación.

Mediante una exploración inicial, se observó que hay 89 imágenes clasificadas como benignas y 86 clasificadas como malignas, es decir, melanomas. Intencionalmente se seleccionaron aproximadamente la misma cantidad de imágenes benignas como malignas para entrenar al modelo.

La base de datos generada con estas 175 imágenes contiene las siguientes características: *image\_name*, *patient\_id*, *sex*, *age\_approx*, *anatom\_site\_general\_challenge*, *diagnosis*, *benign\_malignant* y *target*.

Estas características provienen del database original, pero no van a ser tenidas en cuenta para entrenar el modelo de *machine learning* (excepto por el *target*), debido a que ninguna de estas característica en particular debería influir en el diagnóstico. Dichos parámetros van a ser posteriormente eliminados del database, dejando solamente aquellos obtenidos mediante las técnicas de procesamiento de imágenes explicadas a continuación.

### **Procesamiento de imágenes**

A modo de demostración de los pasos realizados para procesar las imágenes y extraer características, se utilizan las dos lesiones vistas en las Imágenes 1 y 2: una benigna y otra maligna.



Imágenes 1 y 2: Lesión benigna y maligna respectivamente

No fue necesario un procesamiento para mejorar las imágenes previo a la segmentación ya que estas no presentaban ruido de manera notoria y el contraste en rasgos generales era suficiente para diferenciar al lunar del fondo al umbralizar.

## Segmentación

En una primera instancia, se aplica la umbralización a la imagen según el método de Otsu para separar, de manera general, la lesión del resto de la piel. Además, se emplearon herramientas de morfología de apertura para eliminar pequeñas agrupaciones de píxeles causadas por irregularidades en la piel.

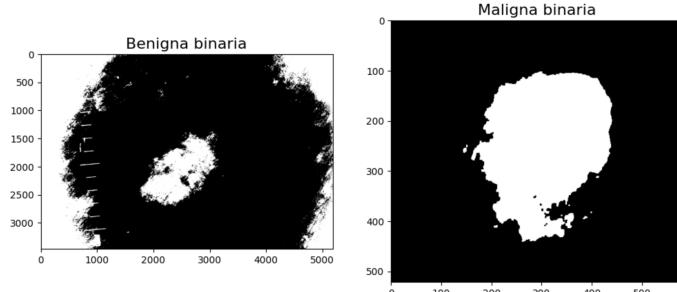


Imagen 3: Binarización mediante Otsu y técnicas de morfología

Luego, se busca 'recortar' la región de interés (ROI), es decir, la lesión, mediante el algoritmo de bounding box. Se selecciona el 'box' de mayor tamaño y más centrado en la imagen original para evitar quedarse con posibles secciones de umbralización en los bordes que no corresponden a las lesiones, como se observa en el caso de la imagen binaria. En la Imagen 4 vemos el resultado de dicho recorte en la imagen a color.

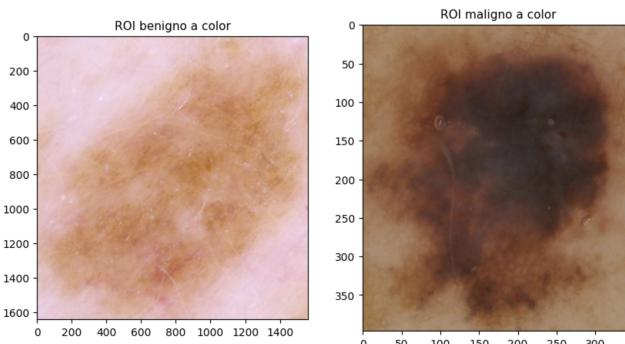


Imagen 4: Recortes de regiones de interés a color.

Finalmente, se multiplican el ROI binarizado con el ROI original para obtener una nueva imagen en la que se vea con claridad la lesión a estudiar sobre un fondo negro. Esto permite una mejor visualización de la imagen, además de facilitar el uso de algunos algoritmos de extracción de características.

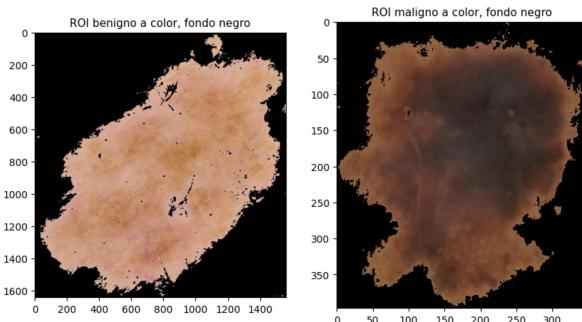


Imagen 5: Recortes de regiones de interés a color con el fondo negro.

## Extracción de características

La extracción de características es un paso fundamental ya que es lo que se usará para entrenar al modelo de *Machine Learning*. A continuación, se detalla brevemente los pasos que se realizaron para obtener las distintas características mencionadas anteriormente.

## Asimetría

Para el análisis de asimetría de las estructuras se diseñó un algoritmo semejante al propuesto por Seidenari et al. [6].

En primer lugar, se divide al ROI en 12x12 cuadrados de igual tamaño y se calcula la media de intensidad para cada cuadrado pequeño y se reemplaza a todo el cuadrado por ese valor de intensidad media, tal como se puede observar en la Imagen 6 .

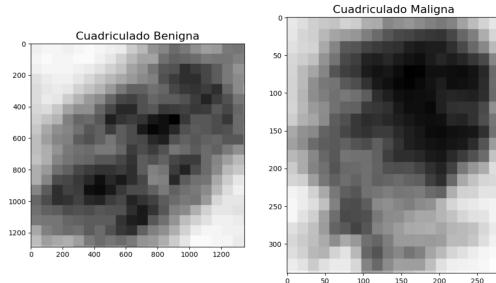


Imagen 6: Cuadriculado de las regiones de interés según el valor medio de cada cuadrado.

Luego, se determina la media de toda la región de interés y cada cuadrado pasa a valer 1 si se encuentra por arriba de la media o 0 si se está por debajo como podemos observar en la Imagen 7 .

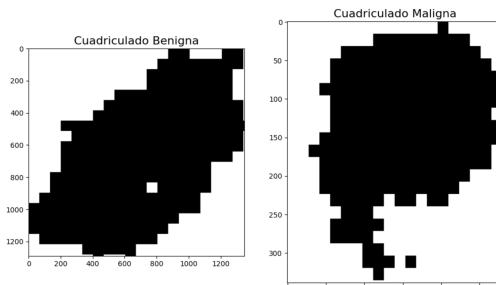


Imagen 7: Cuadriculado de las regiones de interés según si supera o no la media de la región de interés.

Dado que se considera una lesión simétrica si presenta simetría en el eje horizontal o vertical, se dividen las imágenes en cuatro cuadrantes y se cuenta la cantidad de cuadrados negros en cada uno. Posteriormente, se calcula la diferencia o error entre la suma de los cuadrantes 1 y 2 contra los cuadrantes 3 y 4 para determinar la asimetría en el eje horizontal. Asimismo, se calcula la diferencia entre la suma de los cuadrantes 1 y 3 contra los cuadrantes 2 y 4 para determinar la asimetría en el eje vertical. Cabe resaltar que se llevó a cabo el cálculo de la asimetría midiendo de varias formas las diferencias entre los cuatro cuadrantes y se decide utilizar la que presenta la mayor correlación.

## Irregularidad de los bordes y Desviación del Círculo

Lo que primero se realiza es binarizar la región de interés con Otsu y determinar el área de la lesión según la cantidad de píxeles segmentados (Imagen 8 ).

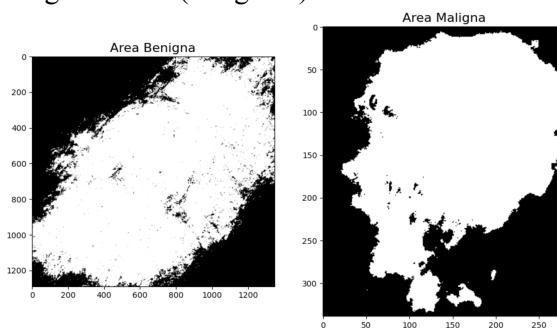


Imagen 8: Binarización mediante Otsu para determinar el área de la lesión.

Posteriormente, se calcula el borde de estas imágenes binarizadas para aproximar el perímetro de la lesión como la cantidad de píxeles blancos resultantes del Algoritmo de Canny (Imagen 9).

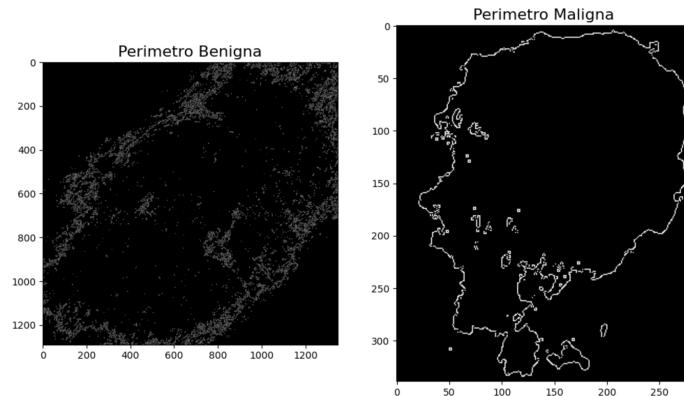


Imagen 9: Algoritmo de Canny a las imágenes binarizadas para aproximar el perímetro.

Con el fin de medir la irregularidad de los bordes, se calcula el centro de masa o punto medio del área segmentada y se mide la distancia euclídea de cada uno de los píxeles del perímetro al centro. De esta forma, es posible determinar que tanta ‘dispersión’ presentan los bordes con respecto a una distancia del centro de masa. Los coeficientes de irregularidad utilizados fueron basados según Majumder et. al [5] , Zghal, et. al [9] y Jain et. al [3], siendo:

$$\text{coeficiente irregularidad de bordes 1} = \text{perímetro/área}$$

$$\text{coeficiente de irregularidad de bordes 2} = \text{perímetro/ máxima distancia euclídea}$$

$$\text{coeficiente de irregularidad de bordes 3} = \text{perímetro} \times \left( \frac{1}{\text{mínima distancia}} - \frac{1}{\text{máxima distancia}} \right)$$

Se termina utilizando el coeficiente de irregularidad de bordes 2 al presentar mayor correlación.

Para medir la desviación del círculo, es decir que tan distinta es la lesión a un círculo homogéneo, se calcula la desviación estándar de todas las distancias euclídeas según:

$$\text{desviación círculo} = \sqrt{\frac{\sum(d-dm)}{n-1}}$$

donde n es la longitud del array de distancia euclídea, d es la distancia euclídea para cada pixel y dm la distancia promedio del centro de masa al perímetro.

### Bordes internos

Dado que las lesiones malignas suelen tener mayores irregularidades dentro de la lesión, se buscan los bordes internos dentro del área previamente encontrada. Se realiza una ecualización del histograma para aumentar el contraste en los niveles de gris presentes solo en el área de la lesión y se utiliza nuevamente el Algoritmo de Canny para identificar los bordes internos. Luego, se resta el perímetro y se normaliza con el área de la lesión. Las imágenes resultantes al buscar los bordes internos se observan en la Imagen 10.

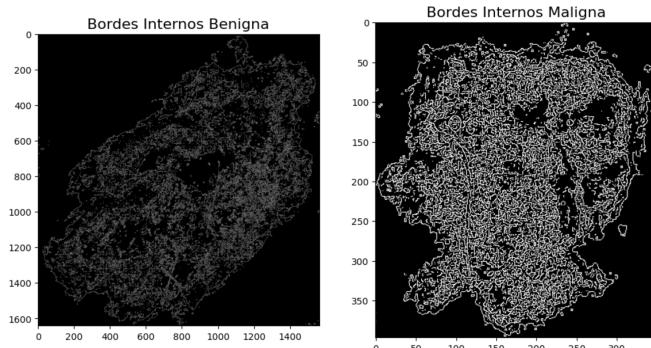


Imagen 10: Bordes internos calculados con Canny.

### Cantidad de colores

La cantidad de colores se calcula a partir de la segmentación presentada en la Imagen 5. Basándose en el criterio de Color en la regla ABCD, más de dos colores en la lesión implicarían poca uniformidad de color y por lo tanto, un rasgo fundamental para diferenciar las lesiones malignas de las benignas.

Para ello, se extraen los colores dominantes de la imagen, sin considerar los píxeles del fondo. Esto se realiza teniendo en cuenta los tonos típicos que pueden aparecer, estableciendo rangos en RGB que permitan diferenciar la presencia de estos píxeles de la imagen. Se busca que haya por lo menos un 1.5% de los píxeles en ese rango para considerarlos como un color dominante. En la Imagen 11 se muestran dos imágenes en las que se observa esta diferencia. Por otro lado, los rangos utilizados, basados en los propuestos por Zgha et al. [8] y por Majumder et al. [5], se encuentran en el Anexo.

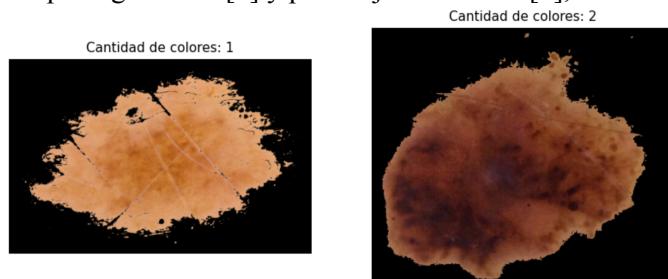


Imagen 11: Cantidad de colores en la lesión segmentada.

### Azul blanquecino

La presencia del azul blanquecino se obtiene de manera similar a la cantidad de colores. Se establecen los rangos de RGB, basados en Zgha et al. [8] y en Majumder et al. [5], que podrían tener los píxeles y se determina un umbral de 0.5%. De esta manera, un pequeño porcentaje de azul blanquecino o de alguna de sus variantes, puede ser reconocido y detectado. Cabe destacar que, en este caso, el umbral se ubica muy cercano al cero dado que la más mínima presencia de esta característica indica que la probabilidad de que se trate de una lesión maligna es alta. En la imagen 12 se observa la diferencia entre una lesión con la presencia de este azul y otra sin. Los rangos utilizados para este caso se encuentran en la Tabla 2 del Anexo.

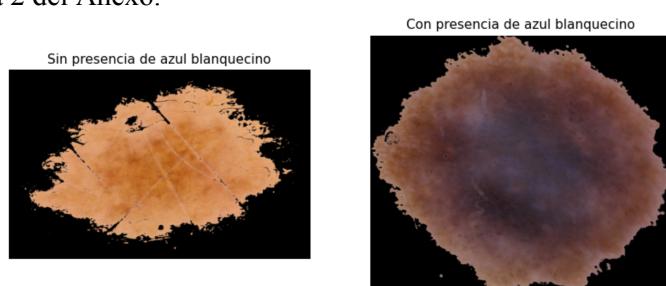


Imagen 12: Presencia de azul blanquecino.

### Intensidad capa azul

La cantidad de la capa azul se calcula como el promedio de las intensidades de todos los píxeles de la imagen del ROI azul (anexo). De esta manera, se busca analizar las diferencias de intensidad en esta capa entre una lesión benigna y otra maligna. La hipótesis detrás de esta característica es que las lesiones benignas presentan colores que en la capa azul se ven más claros (píxeles con valores más cercanos a 255) por lo que el promedio debería ser mayor que en las imágenes de lesiones malignas (más píxeles con valores cercanos a 0).

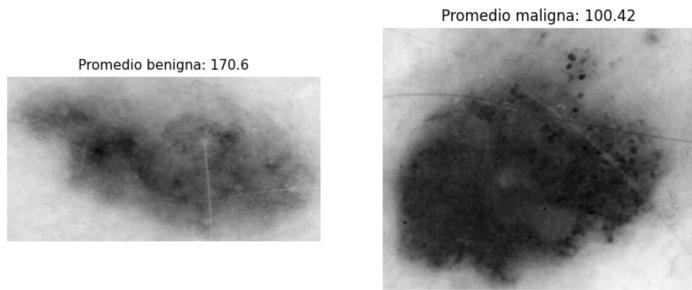


Imagen 13: Intensidad promedio de la capa azul.

### Métricas de texturas

De acuerdo con Kavitha [4], la textura de la piel juega un papel crucial en el diagnóstico y análisis del melanoma. Las características texturales de una lesión en la piel, como la rugosidad, la regularidad, y la variabilidad en color y tono, pueden ser indicativos de la presencia de melanoma.

Como punto de partida para el análisis de texturas, se realizó el cálculo de la matriz de correlación. Esta matriz permite cuantificar la relación entre los píxeles de una imagen, lo que sirve para clasificar las lesiones cutáneas. La misma muestra como la intensidad de un píxel está relacionada con la intensidad de otros píxeles vecinos. Luego, se utilizó esta matriz para calcular las métricas de energía, entropía y correlación.

### Energía

Para realizar el cálculo de la energía se utilizó la siguiente fórmula:

$$f_1 = \sum_{i,j} g(i,j)^2$$

La energía refleja la uniformidad y la repetición de patrones de intensidad. Por lo tanto, las lesiones malignas suelen tener patrones de crecimiento más agresivos y desorganizados, lo que podría traducirse en una menor energía en la matriz de coocurrencia.

### Entropía

Para el cálculo de la entropía a partir de la matriz de correlación, se utilizó la siguiente fórmula:

$$f_2 = \sum_{i,j} g(i,j) \log_2 g(i,j) \text{ si } g(i,j) \neq 0, 0 \text{ si } g(i,j) = 0$$

La entropía mide la aleatoriedad y la complejidad de la distribución de intensidad en la imagen. Esta métrica cuantifica cuán aleatoria es la distribución de los niveles de intensidad de los píxeles, lo que habla sobre la irregularidad y el desorden presentes en la textura de la piel. En el diagnóstico del melanoma, la entropía puede ser una medida de heterogeneidad o uniformidad.

## Correlación

Para realizar el cálculo de la correlación se utilizó la siguiente fórmula:

$$f_3 = \sum_{i,j} \frac{(i-\mu)(j-\mu)g(i,j)}{\sigma^2}$$

La correlación ayuda a medir la homogeneidad o la variabilidad espacial de las texturas en las imágenes dermatológicas. Nos da información sobre las propiedades estructurales de las lesiones cutáneas. Se calcularon los tres parámetros para todos los ROI y se utilizaron como clasificadores para el modelo de Machine Learning.

## Clasificación de imágenes

El objetivo final del trabajo es lograr predecir con algún algoritmo de Inteligencia Artificial la probabilidad de que un lunar sea maligno. No se busca que clasifique por sí (1) o por no (0) las distintas imágenes de las lesiones, sino que el modelo empleado asigne una probabilidad de que ese lunar en particular sea maligno. Por lo tanto, mientras esa probabilidad sea baja es debido a que el modelo considera que el lunar es benigno, y de lo contrario, maligno.

## Machine Learning

Para comenzar a entrenar el modelo con las 175 imágenes clasificadas en la columna *target* como 0 si las lesiones son benignas y como 1 si son malignas, se busca la correlación de las características extraídas previamente con la variable *target*. Como se puede apreciar en la siguiente tabla, la mayoría de las características presentan una correlación de entre 0,15 y 0,40 con el target, lo cual indica que los parámetros calculados están aportando información relevante para lograr clasificar las imágenes de los lunares.

target	<b>1.000000</b>
Asimetria	<b>0.234369</b>
Coef Irregularidad	<b>0.208607</b>
Desviacion Circulo	<b>0.191987</b>
Bordes	<b>0.269504</b>
Cantidad colores	<b>0.398944</b>
Azul maligno	<b>0.157414</b>
Intensidad capa azul	<b>-0.370225</b>
Energia	<b>0.211039</b>
Entropia	<b>-0.348378</b>
Correlacion	<b>-0.040000</b>

Para comenzar a entrenar el modelo, se separan los 175 datos en un grupo de *train* (70%) y otro grupo de *test* (30%). En el grupo *train* se usará para entrenar el modelo, y el grupo *test* para evaluar el desempeño, es decir, sobre las características del grupo *test*, se aplica el modelo y se predice el *target*, y luego se compara con el *target* real para ver si predijo correctamente o no el modelo.

Para poder decidir y encontrar el modelo que mejor se adapte a estos datos, se probaron cuatro modelos principales: *SVC*, *DecisionTreeClassifier*, *KNeighborsClassifier* y *RandomForestClassifier*. Para cada modelo se realizó un ajuste de hiperparámetros para lograr el mayor *accuracy\_score* posible. Finalmente se obtuvo el modelo definitivo:

```
RandomForestClassifier  
RandomForestClassifier(max_depth=5, n_estimators=30, random_state=65)
```

Se ajustó el modelo elegido para predecir el *target* (0 o 1) del grupo *test*, y así poder evaluar las métricas del modelo.

## Métricas de evaluación

Para la evaluación cuantitativa del rendimiento del modelo se utilizaron las siguientes métricas definidas como:

$$\text{Precisión} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\text{Especificidad} = \frac{VN}{VN + FP}$$

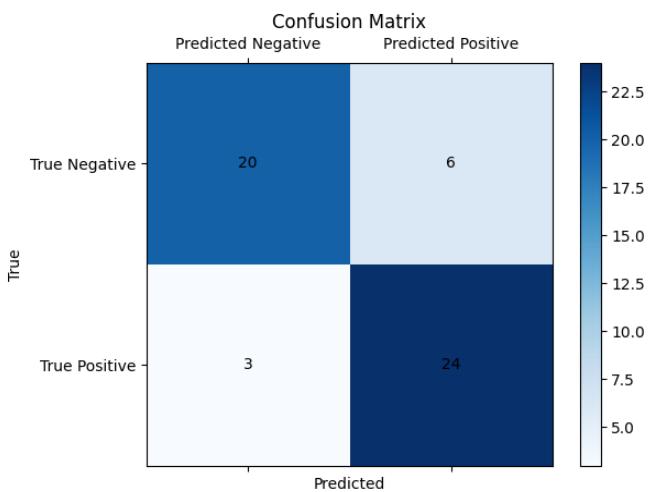
$$\text{Sensibilidad (recall)} = \frac{VP}{VP + FN}$$

Los resultados obtenidos para el *test* son los siguientes:

$$\text{Precisión} = 83,02\%$$

$$\text{Especificidad} = 76,92\%$$

$$\text{Sensibilidad (recall)} = 88,88\%$$



En la Figura 15 del Anexo se muestra la curva ROC (Característica Operativa del Receptor) obtenida.

## Resultados

Viendo que los resultados de la evaluación del modelo son prometedores, se procedió a evaluar el modelo en un grupo de imágenes también extraídas al azar de la misma base de datos, pero que no fueron usadas para *train* ni *test*. Lo que se le ingresa al modelo son las características extraídas del procesamiento de imágenes para una imagen en particular, y se le pide al modelo que devuelva una probabilidad de que esa lesión sea maligna. Se devuelve la probabilidad para no condicionar por 0 o 1 el resultado, sino estimar un porcentaje. A modo de ejemplo, a la imagen benigna de referencia el modelo le asigna un 16,625% de probabilidad, y a la imagen maligna el modelo le asigna 78,13% de probabilidad.

## Interfaz

La interfaz es una herramienta en la que se carga la imagen que se desea clasificar y como resultado devuelve los valores calculados para cada una de las métricas calculadas, además de una probabilidad de que la lesión sea maligna.

En la Imagen 14, se presentan dos imágenes en las que se observa cómo queda la interfaz al cargar una imagen: una benigna y otra maligna. Se observa una sección donde se carga la imagen, otra sección con un display para la original y otro para la segmentada y, por último, el área donde se visualizan las métricas y los valores obtenidos. Además, para cada una de las características extraídas, se presenta un valor de referencia con el objetivo de aportar información a quien lea los resultados obtenidos. Estas referencias corresponden a los valores de la mediana para el análisis de la característica específica para todas las imágenes que se utilizaron para entrenar el modelo.

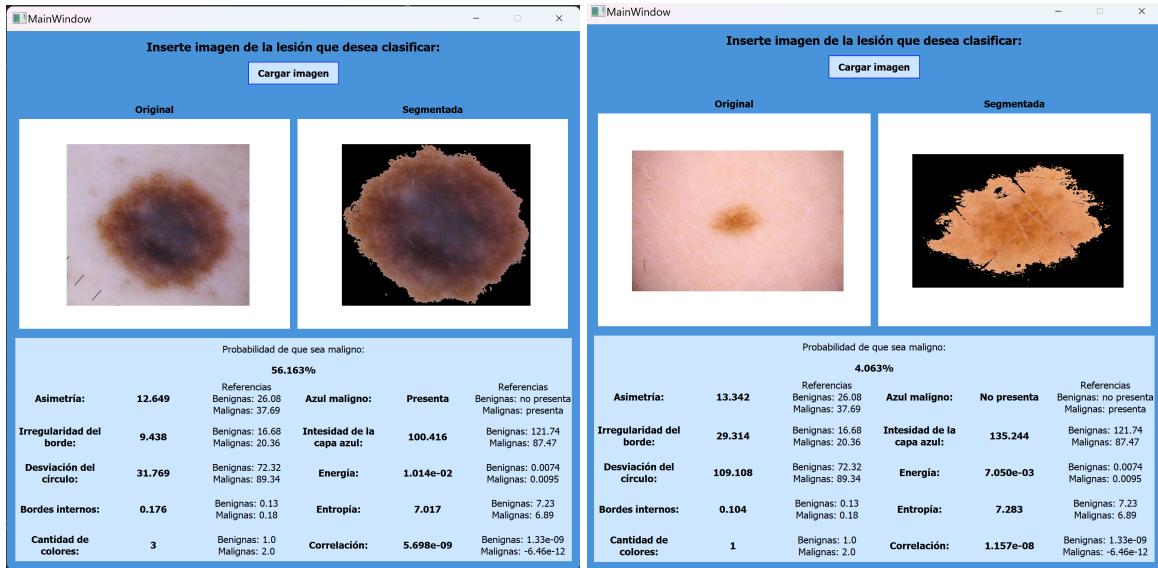


Imagen 16: Muestras de la interfaz con una lesión maligna y otra benigna.

## Conclusión

Se concluye que el algoritmo generado es eficaz en la clasificación de lesiones malignas o melanomas de manera automática y precisa, dado que presenta una precisión de 83,02%, una especificidad de 76,92% y una sensibilidad o *recall* de 88,88%. A su vez, se encuentra integrado a una interfaz funcional.

Es importante destacar que el *target* de las base de datos clasifica mediante estudios histopatológicos, es decir, biopsias. Aunque esta metodología proporciona una base objetiva y médica respaldada, se considera que hubiese sido mejor trabajar sobre una clasificación inicial basada en la evaluación visual de dermatólogos. Esto es debido a que nuestro algoritmo extrae métricas y características que son basadas en forma, color, textura, las cuales se utilizan para entrenar el modelo. Se sostiene, entonces, que haber usado como entrenamiento un database clasificado según un experto en lugar de una biopsia, hubiese dado mejores resultados en cuanto a la sensibilidad y precisión del modelo.

Por otro lado, la cantidad de imágenes utilizadas para entrenar el modelo podría aumentarse para lograr mejores resultados. En este caso, el trabajo se encontraba limitado por un tema de RAM al correr el código y que la base de datos eran pocas las imágenes malignas en comparación con las benignas que cumplieran las especificaciones previamente mencionadas (pelos gruesos, bordes negros, artefactos no correspondientes a las lesiones, etc.)

En conclusión, se ha desarrollado un clasificador mediante el procesamiento de imágenes, lo cual ha posibilitado la extracción de las características necesarias para identificar lesiones a través de un modelo de Machine Learning. Este proceso se llevó a cabo aplicando los conocimientos adquiridos durante la materia, tales como el mejoramiento de la imagen, la detección de bordes, la segmentación y el análisis de texturas. Estos enfoques no solo se emplearon para cumplir con la regla ABCDE, sino también para innovar en la adquisición de características particulares de lesiones malignas y aumentar la eficiencia del clasificador.

## **Bibliografía**

1. *Argentina.gob.ar.* (2021, 23 noviembre). *Estadísticas - incidencia.*  
<https://www.argentina.gob.ar/salud/instituto-nacional-del-cancer/estadisticas/incidencia>
2. *International skin image collaboration.* <https://www.isic-archive.com/> Accessed: 2019-03-04.
3. *Jain, S., Jagtap, V., & Pise, N.* (2015). *Computer aided melanoma skin cancer detection using image processing.* *Procedia Computer Science*, 48, 735-740.  
<https://doi.org/10.1016/j.procs.2015.04.209>
4. *J. C. Kavitha and A. Suruliandi*, "Texture and color feature extraction for classification of melanoma using SVM," *2016 International Conference on Computing Technologies and Intelligent Data Engineering (ICCTIDE'16)*, Kovilpatti, India, 2016, pp. 1-6, doi:  
10.1109/ICCTIDE.2016.7725347.
5. *Majumder, S., & Ullah, M. A.* (2019). *Feature extraction from dermoscopy images for melanoma diagnosis.* *SN Applied Sciences*. <https://doi.org/10.1007/s42452-019-0786-8>
6. *Seidenari Stefania, Giovanni Pellacani, and Constantino Grana.* *Asymmetry in Dermoscopic Melanocytic Lesion Images: a Computer Description Based on Colour Distribution.* 2006.
7. *The International Agency for Research on Cancer (IARC).* (s. f.). *Global Cancer Observatory.*  
<https://gco.iarc.fr/>
8. *Zghal, N. S., & Derbel, N.* (2020). *Melanoma skin cancer detection based on image processing.* *Current Medical Imaging Formerly Current Medical Imaging Reviews*, 16(1), 50–58.  
<https://doi.org/10.2174/1573405614666180911120546>.

## Anexo

	Rango 1	Rango 2	Rango 3	Rango 4	Rango 5	Rango 6	Rango 7
R	200 - 255	180 - 255	180 - 255	0 - 125	153 - 198	50 - 153	0 - 153
G	200 - 255	180 - 255	115 - 180	0 - 115	50 - 153	0 - 170	100 - 125
B	200 - 255	185 - 255	180 - 255	0 - 100	0 - 100	0 - 100	100 - 180

Tabla 1: Rangos utilizados para determinar la cantidad de colores

	Rango 1	Rango 2	Rango 3	Rango 4	Rango 5	Rango 6
R	148 - 152	123 - 127	98 - 102	98 - 102	48 - 102	0 - 2
G	123 - 127	123 - 127	98 - 102	123 - 127	98 - 102	98 - 102
B	148 - 152	148 - 152	123 - 127	148 - 152	148 - 151	148 - 152

Tabla 2: Rangos utilizados para determinar la presencia de azul blanquecino

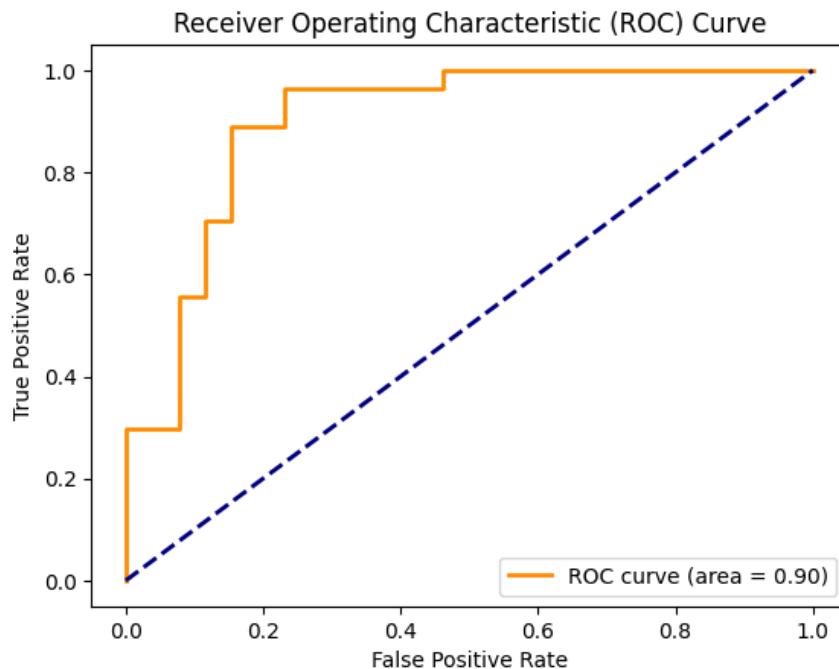


Imagen 15: Curva ROC (Característica Operativa del Receptor) del modelo.